UNIVERSIDAD TORCUATO DI TELLA
Licenciatura en Tecnología Digital

TRABAJO PRÁCTICO 3
TECNOLOGÍA DIGITAL 6: INTELIGENCIA ARTIFICIAL

Santiago Barreiros, Lucas Estrada, Marcos Bustamante y Julian Ippolito

Segundo semestre 2026

---

1. Introducción

Una CNN propia de 2 capas convolucionales alcanza **87,4 % de accuracy en test** sobre EuroSAT RGB; una ResNet18 preentrenada en ImageNet, con fine-tuning parcial, llega a **97 %** en menos épocas, aunque cada época cuesta unas 3 veces más.

El trabajo práctico introduce la visión computacional con redes neuronales convolucionales (CNNs) en PyTorch. La tarea es clasificar el uso del suelo de recortes de imágenes satelitales Sentinel-2 en 10 clases. El trabajo sigue las tres consignas del enunciado:

1. Diseñar y entrenar una CNN propia desde cero, con data augmentation, monitoreo de loss y accuracy, y control del flujo de gradientes.
2. Evaluarla en test, analizar la matriz de confusión y visualizar el espacio latente con t-SNE.
3. Aplicar transfer learning con ResNet18 y comparar ambos enfoques en convergencia, métricas y tiempo por época.

Todo el código está en `model.ipynb`.

2. Datos y pipeline

Se usó la versión RGB de EuroSAT: 27.000 imágenes de 64×64 píxeles en 10 clases. Se respetaron las particiones que trae el dataset de Kaggle (70 / 20 / 10 %).

Partición	Imágenes	Por clase
Train	18.900	1.400 a 2.100
Validación	5.400	400 a 600
Test	2.700	200 a 300

Tabla 1. Particiones del dataset.

Las clases no están perfectamente balanceadas: Pasture tiene un tercio menos de imágenes que Forest o Residential. La diferencia es moderada, así que no se aplicó ninguna corrección.

Carga. Una clase `EuroSATDataset` lee cada CSV (ruta y etiqueta), abre la imagen con PIL y le aplica las transformaciones. Tres `DataLoader` con batch de 32 alimentan el entrenamiento; solo el de train mezcla los datos.

Normalización. Para la CNN propia se calculó la media y el desvío por canal sobre 3.000 imágenes de train (media R, G, B = 0,350, 0,384, 0,418). Se usaron solo datos de train para no filtrar información de validación o test.

Data augmentation. Solo en train se aplican flips horizontales y verticales (p = 0,5) y rotaciones aleatorias de 0°, 90°, 180° o 270°. Las imágenes satelitales son cenitales y no tienen "arriba": un bosque o un río rotado sigue siendo la misma clase. Estas transformaciones generan hasta 8 versiones válidas de cada imagen sin deformarla ni agregar bordes vacíos, como haría una rotación en un ángulo arbitrario. No se alteraron los colores porque el color distingue clases (agua, vegetación, cultivos).

3. CNN propia entrenada desde cero

La red propia termina con 93,2 % de accuracy en train y 87,0 % en validación tras 25 épocas, con un pico de 88,3 % en la época 15.

3.1 Arquitectura

Se eligió una arquitectura chica: dos bloques de convolución, LeakyReLU y max pooling, seguidos de dos capas densas. Con imágenes de 64×64 alcanza para que la red aprenda texturas y formas locales sin un costo de cómputo alto.

Capa	Configuración	Salida	Parámetros
conv1	16 filtros 3×3, padding 1, LeakyReLU	16 × 64 × 64	448
pool1	max pooling 2×2	16 × 32 × 32	0
conv2	32 filtros 3×3, padding 1, LeakyReLU	32 × 32 × 32	4.640
pool2	max pooling 2×2	32 × 16 × 16	0
fc1	densa, LeakyReLU	128	1.048.704
fc2	densa (logits)	10	1.290

Tabla 2. Arquitectura de la CNN propia.

El total es 1.055.082 parámetros, el 99 % en fc1, que recibe el mapa aplanado de 8.192 valores. Se usó LeakyReLU en lugar de ReLU para que las neuronas con entrada negativa sigan pasando un gradiente pequeño y no queden "muertas".

3.2 Entrenamiento

- Pérdida: cross-entropy.
- Optimizador: SGD con learning rate 0,01 y momentum 0,9.
- 25 épocas, batch de 32, semilla 67.
- En cada época se registran loss y accuracy de train y validación, y el tiempo de cómputo.

La curva de train mejora de forma sostenida (loss de 1,23 a 0,21). La loss de validación baja hasta unas 0,37 entre las épocas 11 y 15 y después se estanca alrededor de 0,42. La brecha final de 6 puntos de accuracy indica un sobreajuste leve a partir de la época 12; guardar el modelo con mejor validación (early stopping) habría dado un resultado algo mejor.

En las primeras épocas la accuracy de validación supera a la de train. Es esperable: el train se mide con augmentation activo y promedia toda la época, mientras que validación se mide al final con los pesos ya mejorados.

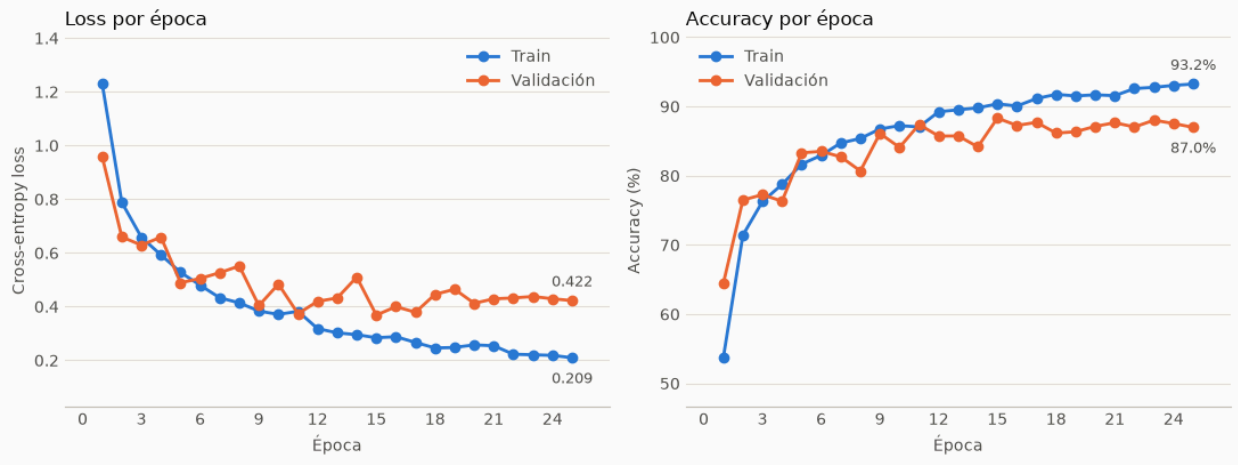


Figura 1. Loss y accuracy por época de la CNN propia, en train y validación.

3.3 Monitoreo de gradientes

Durante las 3 primeras épocas se registró la norma del gradiente de los pesos de cada capa cada 20 batches (591 batches por época). No hay señales de vanishing ni de exploding gradients:

- En el primer batch las normas son bajas (0,05 a 0,2) y en menos de 20 batches suben a valores cercanos a 1.
- Desde ahí las cuatro capas oscilan entre aproximadamente 0,7 y 8, sin tendencia a crecer ni a desaparecer.
- conv1, la capa más lejana a la salida, recibe gradientes del mismo orden que fc2. La señal llega bien a las primeras capas, algo esperable en una red poco profunda con LeakyReLU.

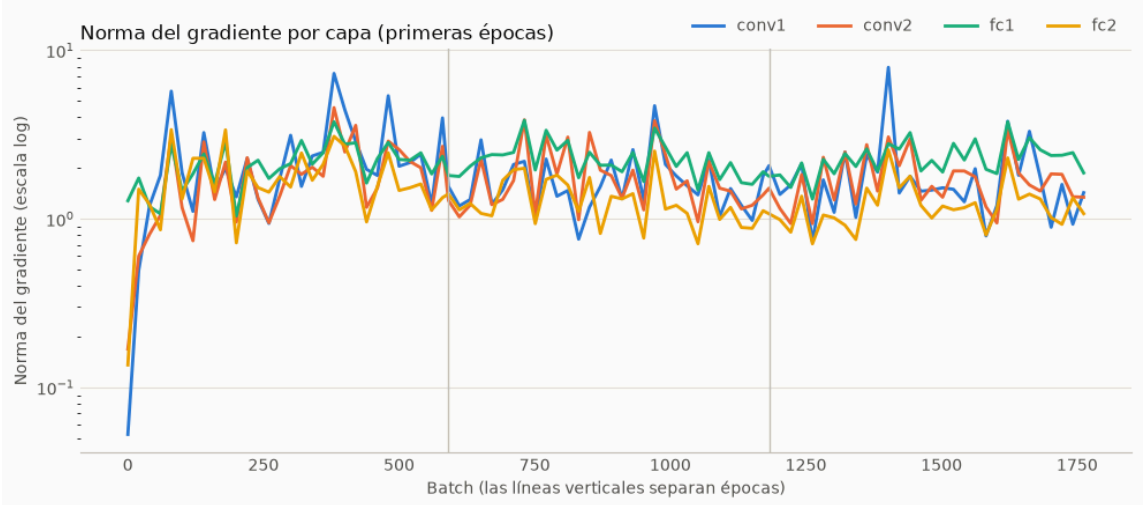


Figura 2. Norma del gradiente por capa durante las 3 primeras épocas (escala logarítmica).

4. Análisis de errores en test

En test (2.700 imágenes) la CNN propia obtiene **87,4 % de accuracy**, loss de 0,416 y F1 macro de 0,87. El rendimiento es muy desigual entre clases: tres superan 0,95 de recall y PermanentCrop se queda en 0,60.

Clase	Precision	Recall
SeaLake	0,96	0,98
Forest	0,95	0,98
Residential	0,96	0,97
River	0,71	0,91
Pasture	0,80	0,90
AnnualCrop	0,90	0,89
Industrial	0,94	0,88
HerbaceousVegetation	0,80	0,82
Highway	0,81	0,76
PermanentCrop	0,89	0,60

Tabla 3. Precision y recall por clase de la CNN propia en test.

4.1 Confusiones más frecuentes

Salen de la matriz de confusión (filas: clase real; columnas: predicción).

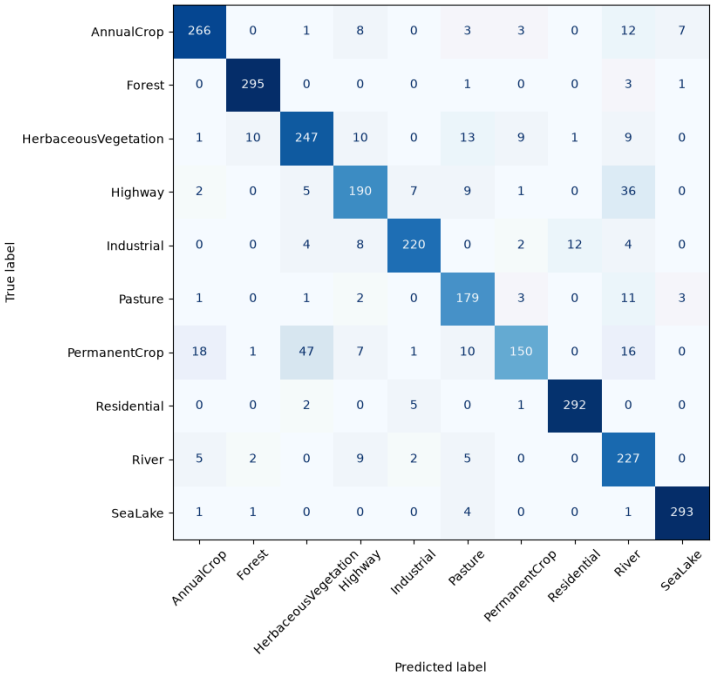


Figura 3. Matriz de confusión de la CNN propia en test.

Clase real	Predicha como	Imágenes	% de la clase
PermanentCrop	HerbaceousVegetation	47	18,8 %
Highway	River	36	14,4 %
PermanentCrop	AnnualCrop	18	7,2 %
PermanentCrop	River	16	6,4 %
HerbaceousVegetation	Pasture	13	4,3 %
Industrial	Residential	12	4,8 %
AnnualCrop	River	12	4,0 %

Tabla 4. Confusiones más frecuentes en test.

PermanentCrop confundido con HerbaceousVegetation. Los cultivos permanentes (viñedos, frutales) son hileras de plantas con pasto entre medio. A 10 m por píxel y en 64×64 las hileras casi no se resuelven, y lo que queda es una textura verde parecida a la vegetación herbácea. Por el mismo motivo PermanentCrop también se confunde con AnnualCrop.

Highway confundido con River. Ambas clases son una estructura lineal fina que cruza un fondo rural. El fondo ocupa la mayor parte de la imagen y es similar en las dos; lo que las distingue es el color y la forma de la línea, un detalle chico para una red de dos capas.

River como clase "imán". River tiene la precision más baja (0,71): recibe 92 falsos positivos de 8 clases distintas. La red parece haber aprendido "hay un elemento lineal" como señal de río, y la dispara con rutas, bordes de parcelas o caminos.

Industrial confundido con Residential. Las dos son zonas construidas con techos y calles grises; la diferencia está en el tamaño y la regularidad de los edificios.

Las clases con mejor rendimiento (SeaLake, Forest, Residential) tienen color y textura homogéneos y muy distintos del resto.

5. Espacio latente

Las clases forman clusters antes de la capa final, pero no todas: los mismos pares que se confunden en la matriz aparecen mezclados en el espacio latente.

Método. Con un forward hook sobre fc2 se capturó su entrada: el vector de 128 dimensiones que sale de fc1, justo antes de la clasificación. Se extrajo para las 2.700 imágenes de test y se proyectó a 2 dimensiones con t-SNE (perplexity 30, inicialización PCA). Se eligió t-SNE porque conserva los vecindarios locales, que es lo que interesa para ver si una clase forma un grupo.

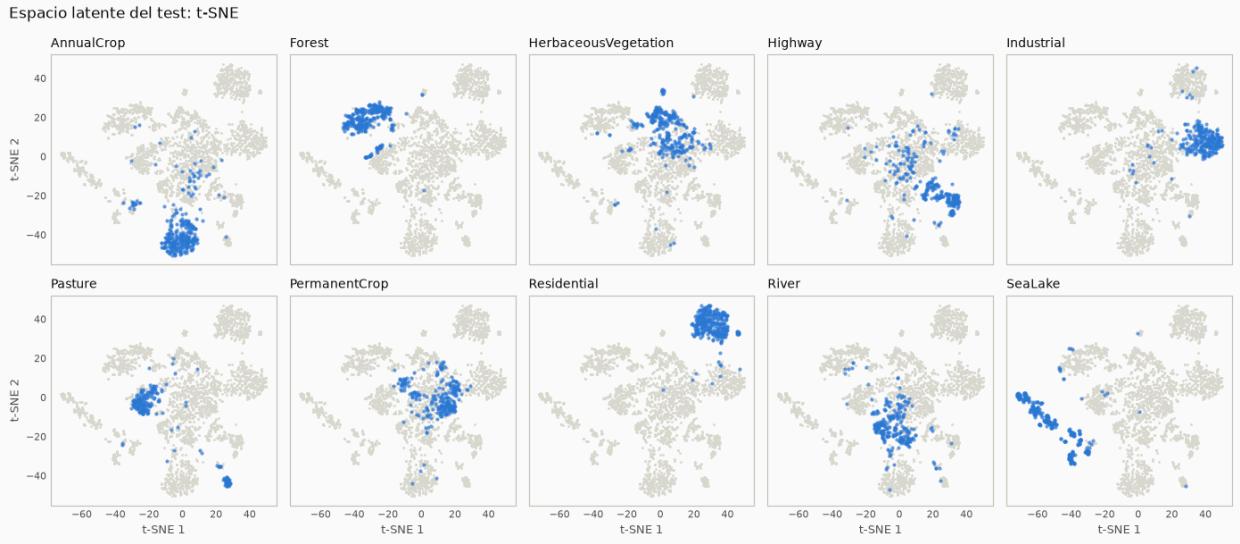


Figura 4. Proyección t-SNE del espacio latente de test. Cada panel resalta una clase sobre el resto.

Lectura. El gráfico tiene un panel por clase con sus puntos resaltados sobre el resto:

- **Clusters compactos y aislados:** Residential, Industrial, Forest, AnnualCrop y SeaLake. Coinciden con las clases de mayor recall.
- **Clusters superpuestos:** PermanentCrop y HerbaceousVegetation ocupan la misma zona central. Highway y River comparten la zona centro inferior, y Highway tiene además un subgrupo separado.
- **Clases partidas en varios grupos:** Pasture tiene un grupo principal y una isla chica aparte; SeaLake forma dos grupos. Podrían ser subtipos visuales (por ejemplo, agua abierta frente a costa), pero habría que revisar esas imágenes para confirmarlo.

Conclusión. Las confusiones ya están en las features que produce la red, no las introduce la última capa. Para mejorar en esos pares hace falta una red que extraiga mejores features, que es lo que aporta el transfer learning. Las distancias entre clusters en t-SNE no tienen significado directo: solo se interpreta qué puntos quedan juntos.

6. Transfer learning con ResNet18

ResNet18 preentrenada supera a la CNN propia desde la primera época: 95,0 % en validación tras 1 época, contra un máximo de 88,3 % de la CNN en 25. En test llega a **97 % de accuracy** y F1 macro 0,97.

6.1 Configuración

- **Modelo:** ResNet18 con pesos de ImageNet (`IMAGENET1K_V1`).
- **Adaptación:** se reemplazó la capa final (1.000 clases) por una lineal de 512 a 10 salidas.
- **Fine-tuning parcial:** se congeló toda la red y se descongeló solo el último bloque residual (`layer4`) y la capa nueva. Son unos 8,4 M de parámetros entrenables sobre 11,2 M. Los primeros bloques detectan bordes y texturas genéricas que sirven tal cual; el último bloque es el más específico de ImageNet y conviene reajustarlo a imágenes satelitales.

- **Entrada:** imágenes reescaladas de 64×64 a 128×128 y normalizadas con media y desvío de ImageNet, que son los que espera la red preentrenada. Mismo data augmentation que la CNN propia.
- **Entrenamiento:** Adam con learning rate 0,001, batch de 32, 10 épocas.

6.2 Comparación

	CNN propia	ResNet18 (transfer learning)
Parámetros entrenables	1,06 M	8,4 M
Resolución de entrada	64×64	128×128
Épocas	25	10
Accuracy de validación, época 1	64,4 %	95,0 %
Mejor accuracy de validación	88,3 % (época 15)	97,7 % (época 8)
Accuracy en test	87,4 %	97 %
F1 macro en test	0,87	0,97
Tiempo por época	≈ 15 s	≈ 47 s
Tiempo total de entrenamiento	≈ 6 min	≈ 8 min

Tabla 5. Comparación entre la CNN propia y ResNet18.

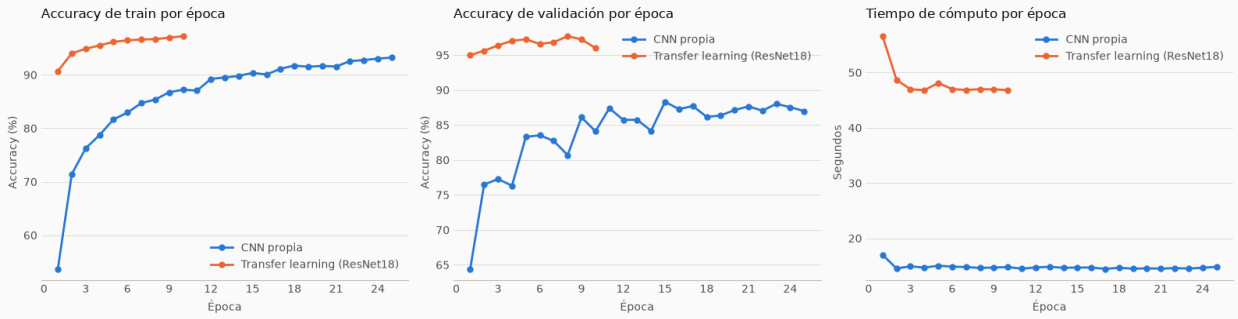


Figura 5. Accuracy de train, accuracy de validación y tiempo de cómputo por época de ambos modelos.

Velocidad de convergencia. ResNet18 converge mucho más rápido: arranca en 95 % y se estabiliza entre 96 % y 98 % desde la época 3. La CNN propia necesita 11 épocas (unos 2,7 min) para pasar el 87 %, un nivel que ResNet18 supera en su primera época (57 s). Aun midiendo en tiempo real y no en épocas, el transfer learning llega antes a cualquier nivel de accuracy.

Rendimiento final. ResNet18 mejora 10 puntos de accuracy y corrige justo las clases débiles de la CNN propia. El recall de PermanentCrop sube de 0,60 a 0,95, el de Highway de 0,76 a 0,91, y la precision de River de 0,71 a 0,94. Las features aprendidas en ImageNet separan mejor texturas finas y estructuras lineales.

Tiempo de cómputo por época. Cada época de ResNet18 tarda unas 3 veces más (47 s contra 15 s). La red es más profunda (18 capas contra 4), procesa imágenes con 4 veces más píxeles y entrena 8 veces más parámetros. Aunque las capas congeladas no calculan gradientes de sus pesos, el forward pasa igual por toda la red. La primera época de ambos modelos es más lenta (57 s y 17 s), probablemente por la inicialización del dispositivo.

La comparación no es del todo pareja: cambian la resolución, el optimizador (Adam contra SGD) y la cantidad de épocas. Aun así, la diferencia de 10 puntos desde la primera época es demasiado grande para atribuirla a esos factores.

7. Conclusiones

- Una CNN chica entrenada desde cero resuelve bien EuroSAT (87,4 % en test) cuando la clase tiene color y textura distintivos, y falla en pares visualmente parecidos: PermanentCrop con HerbaceousVegetation y Highway con River.
- El data augmentation con flips y rotaciones de 90° aprovecha que las imágenes satelitales no tienen orientación, y el monitoreo de gradientes confirmó que la red entrenó sin vanishing ni exploding gradients.
- El espacio latente muestra que esos errores nacen en las features: las clases confundidas ya están mezcladas antes de la capa final.
- El transfer learning con ResNet18 sube la accuracy a 97 % y converge en 1 a 3 épocas, a cambio de unas 3 veces más tiempo por época. Para este problema es claramente la mejor opción.
- Mejoras posibles para la CNN propia: early stopping sobre validación, dropout o weight decay para reducir el sobreajuste, y un tercer bloque convolucional para captar patrones más finos.